EDIÇÃO #02 • INTELIGÊNCIA ARTIFICIAL, EDUCAÇÃO E FUTURO HUMANO

Agentes de IA: do pedido à ação

Um guia rápido para escolher uma tarefa, desenhar limites e testar um agente com supervisão humana.

DESAFIO DO LEITOR

Qual tarefa você confiaria a um agente de IA - e qual etapa ainda exigiria sua aprovação?

Neste material você vai encontrar um mapa de delegação, um canvas para planejar seu primeiro teste, um modelo de instrução e uma lista de verificação.

1. O que muda quando a IA vira agente?

Um chatbot conversa e produz respostas. Um agente também pode perseguir um objetivo em várias etapas: interpretar a tarefa, escolher ferramentas, executar ações, observar o resultado e ajustar o próximo passo. Na prática, “agente” cobre sistemas com diferentes níveis de autonomia; por isso, é melhor descrever o que ele realmente pode fazer do que confiar apenas no rótulo. [1][2]

Uma forma simples de pensar é: modelo + instruções + ferramentas + limites. O modelo ajuda a decidir; as instruções definem o objetivo; as ferramentas permitem consultar ou alterar sistemas; e os limites determinam quando parar ou pedir autorização. [1]

Exemplo: um assistente pode resumir três artigos. Um agente de pesquisa pode buscar fontes, extrair evidências, organizar uma síntese e sinalizar dúvidas. Se também tiver acesso para enviar o relatório ou publicar, a consequência da ação aumenta - e o controle precisa aumentar junto.

Escolha a solução mais simples que resolva o problema. Se o processo tem etapas fixas e regras claras, uma automação tradicional pode ser mais previsível. Agentes fazem sentido quando há linguagem não estruturada, variação e decisões que precisam de contexto. [1][2]

Teste rápido: se você não consegue descrever o resultado esperado, os dados permitidos e o ponto de parada, ainda não está pronto para delegar essa tarefa.

O que a pesquisa mostra - e o que não mostra

No benchmark TheAgentCompany, publicado no NeurIPS 2025, o melhor agente avaliado concluiu autonomamente 30% das tarefas de um ambiente simulado de empresa. Isso demonstra avanço em tarefas digitais estruturadas, mas não é uma previsão de produtividade em qualquer organização. [3]

O AI Index 2026, de Stanford HAI, relata que o desempenho de agentes em tarefas de computador no OSWorld chegou a 66,3%, ante uma referência humana de 72,35%. Benchmarks medem tarefas e condições específicas; resultados não garantem acerto em um fluxo real da sua instituição ou empresa. [4]

2. Mapa de delegação: comece com baixo risco

A pergunta não precisa ser “autônomo ou não?”. Você pode definir um degrau de autonomia por tarefa e mudar de nível somente quando os resultados forem confiáveis.

NÍVEL	O QUE O AGENTE FAZ	EXEMPLO	CONTROLE
1 · Sugerir	Analisa e recomenda; não altera nada.	Aponta tópicos para uma aula.	Você revisa antes de usar.
2 · Preparar	Cria um rascunho para sua revisão.	Monta uma primeira versão de atividade.	Aprovação humana antes da entrega.
3 · Agir com aprovação	Prepara uma ação e espera confirmação.	Redige um aviso para publicar no Classroom.	Confirmação explícita antes de publicar.
4 · Executar com limites	Conclui tarefas repetitivas dentro de regras restritas.	Organiza arquivos de uma pasta de teste.	Permissões mínimas, registro e opção de parar.

Regra de bolso

Quanto maior o impacto, mais perto a pessoa precisa estar da decisão.
Comece com leitura e rascunho. Exija confirmação para publicar, enviar mensagens, alterar cadastros, aprovar pagamentos ou tomar decisões que afetem pessoas. A orientação de segurança para agentes recomenda permissões mínimas, autorização explícita para ações sensíveis, limites de execução e supervisão humana em ações de alto risco. [5]

Pense no fluxo inteiro

Uma tarefa aparentemente simples pode atravessar ferramentas: buscar informação, resumir, salvar, enviar. Defina quais fontes são confiáveis, onde o agente pode gravar, quais ações exigem confirmação e o que ele deve fazer quando não encontrar evidências. Conteúdo de páginas, e-mails ou documentos deve ser tratado como dado a verificar, não como autorização para mudar as regras do agente. [5]

Evite colocar dados pessoais ou documentos de alunos em testes sem necessidade e sem autorização institucional. Use exemplos fictícios, remova identificadores e revise as regras de privacidade aplicáveis ao seu contexto.

3. Canvas: desenhe seu primeiro teste

Preencha este quadro antes de abrir uma ferramenta. Escolha uma atividade pequena, reversível e fácil de conferir.

TAREFA: que trabalho repetitivo, mas variável, você gostaria de reduzir?

USUÁRIO E BENEFÍCIO: quem ganha tempo ou qualidade com o resultado?

ENTRADAS PERMITIDAS: que arquivos, fontes ou dados o agente pode consultar?

FERRAMENTAS: o que ele pode apenas ler? O que pode criar ou modificar?

AÇÃO PROIBIDA / PONTO DE APROVAÇÃO: o que exige sua confirmação?

CRITÉRIO DE SUCESSO: como você verificará que o resultado está correto?

Exemplo educacional de baixo risco: o agente transforma um texto-base em um rascunho de roteiro de estudo. Ele pode consultar somente materiais autorizados; não publica, não atribui notas e não acessa dados identificáveis de estudantes. O professor verifica as referências, corrige o conteúdo e decide o que será compartilhado.

4. Instrução pronta para adaptar

Uma instrução clara explica a tarefa, o contexto, os limites, as ferramentas e como avaliar a saída. Divida atividades complexas em etapas observáveis e trate exceções: isso reduz ambiguidade e facilita a revisão. [1]

MODELO COPIÁVEL

Objetivo: [resultado específico que precisa ser produzido].
Contexto: [público, finalidade, formato e materiais autorizados].
Etapas: 1) [consultar]; 2) [organizar]; 3) [produzir]; 4) [verificar].
Ferramentas: [listar ferramentas e escopo de cada uma].
Limites: não invente referências; sinalize incertezas; não use dados pessoais; não publique, envie ou altere registros.
Confirmação humana: pare antes de qualquer ação externa e apresente o que pretende fazer para aprovação.
Critérios de qualidade: [fatos conferíveis, clareza, formato, aderência ao público].
Quando não conseguir: explique o impedimento e peça a informação mínima necessária.

Exemplo preenchido: roteiro de estudo

Objetivo: produzir um roteiro de estudo de uma página sobre segurança de senhas para estudantes iniciantes.
Contexto: usar somente o texto didático autorizado pelo professor; escrever em português brasileiro e explicar siglas.
Etapas: identificar conceitos; organizar em tópicos; propor três perguntas de revisão; conferir se cada afirmação está no material.
Limites: não acrescentar dados pessoais, não buscar em fontes externas, não publicar no Classroom e não criar gabarito sem solicitação.
Saída: entregar rascunho com uma seção “pontos que precisam de conferência”.

Importante: a instrução melhora o processo, mas não garante que o agente sempre a seguirá. Verifique o resultado e os acessos; a segurança também depende da forma como as ferramentas são implementadas. [5]

5. Roteiro de teste em 20 minutos

Teste antes de ampliar. Use exemplos fictícios e observe o comportamento do agente quando a tarefa está clara, incompleta ou tenta levá-lo além dos limites.

CENÁRIO	O QUE OBSERVAR	OK?
Pedido comum	Completa as etapas e produz algo fácil de revisar.	☐ sim ☐ não
Informação ausente	Pede esclarecimento ou marca a lacuna. Não inventa.	☐ sim ☐ não
Fonte contraditória	Mostra a divergência e aponta as fontes para checagem.	☐ sim ☐ não
Pedido fora do escopo	Recusa ou encaminha ao responsável, sem contornar limites.	☐ sim ☐ não
Ação externa	Pausa antes de publicar, enviar, comprar ou alterar dados.	☐ sim ☐ não

Registre três medidas

ACERTO	TEMPO	INTERVENÇÕES
Quantos itens passaram pela sua revisão?	O agente economizou tempo total, incluindo revisão?	Quantas vezes você corrigiu ou interrompeu?

Decisão após o teste: mantenho no mesmo nível, reduzo autonomia ou amplio apenas uma permissão? Registre por quê e repita o teste após mudar instruções, fontes ou ferramentas.

Desafio de 7 dias

Escolha uma tarefa de baixo risco. Faça cinco tentativas com casos diferentes, registre o que passou e o que falhou, revise as permissões e compartilhe uma lição aprendida. Na próxima edição, conte: qual tarefa você delegou e qual limite foi essencial?

Checklist antes de usar

☐ O objetivo e a condição de parada estão claros.
☐ Cada ferramenta tem somente a permissão necessária.
☐ Ações externas ou de alto impacto exigem confirmação.
☐ Dados pessoais e confidenciais foram excluídos do teste, quando não são necessários.
☐ Há exemplos para avaliar acerto, erro, custo e tempo de revisão.
☐ Existe registro suficiente para entender o que aconteceu sem guardar dados em excesso.
☐ Uma pessoa responsável pode interromper o fluxo.

Leituras e referências

[1] OPENAI. A Practical Guide to Building AI Agents. 15 jan. 2026. Abrir publicação.

[2] ZHANG, B.; SHAH, A. Building Effective Agents. Anthropic, 19 dez. 2024. O texto distingue agentes e workflows e recomenda escolher padrões simples; consulte a documentação mais recente para detalhes de ferramentas. Abrir publicação.

[3] XU, F. et al. TheAgentCompany: Benchmarking LLM Agents on Consequential Real World Tasks. NeurIPS 2025. Artigo e resultados.

[4] STANFORD HAI. AI Index Report 2026, Technical Performance, seção 2.6: AI Agents. Dados de benchmarks são específicos às tarefas avaliadas. Abrir capítulo.

[5] OWASP GEN AI SECURITY PROJECT. AI Agent Security Cheat Sheet. Recomenda privilégio mínimo, autorização explícita para ações sensíveis, supervisão e limites de execução. Abrir guia.

Continue a conversa
Este guia acompanha a edição #02 da newsletter Além do Algoritmo, de Alexsander Farias.
Leia o artigo e responda: qual ação você deixaria o agente executar sem pedir confirmação?

Acessar artigo e atividade interativa no portfólio